

杭州电子科技大学

本科毕业设计(论文)

(2025 届)

基于 YOLO 的实验室进出人员及物

题 目 品监控系统设计与实现

学 院 计算机学院

专 业 计算机科学与技术

姓 名 潘格言

班 级 21052315

学 号 21051522

指导教师 张聪

完成日期 2025 年 6 月

诚信承诺

我谨在此承诺：本人所写的毕业论文《基于 YOLO 的实验室进出人员及物品监控系统设计与实现》均系本人独立完成，没有抄袭行为，凡涉及其他作者的观点和材料，均作了注释，若有不实，后果由本人承担。

承诺人（签名）：

2025 年 5 月 6 日

摘 要

目标检测算法旨在对图像或视频中的特定目标进行精准定位与识别，通过边界框或掩码标记出目标的位置和类别，以便后续对目标进行跟踪、计数或行为分析等高级处理。监控摄像头能够拍摄实时画面，然而，大多数摄像头清晰度往往不够高，基于人眼对于摄像头画面的分析误差较大，对于复杂背景的适应能力较差，往往不够及时有效，不能很好的保障安全需求。本文聚焦日益重要的实验室安全问题，采用了 Yolov5、PP-YOLOE 等多种目标检测模型，能够有效的分析监控画面，为实验室安全提供最大程度的保障。

此外，本文还开发了响应的系统用于人机交互。该平台不仅支持原监控画面的展示，还能呈现过往发生的实验室进出时间节点以及携带的物品信息。通过使用 Flask 库包暴露接口，调用脚本，使得用户可以在 PC 端更快捷的使用这个模型的功能，为用户提供更便捷的体验。

关键词：目标检测；Yolov5 模型；PP-YOLOE 模型；实验室安全；监控系统

ABSTRACT

The object detection algorithm aims to precisely locate and recognize specific targets in images or videos. It marks the position and category of the targets through bounding boxes or masks, so as to facilitate subsequent advanced processing such as tracking, counting or behavior analysis of the targets. Surveillance cameras can capture real-time images. However, the clarity of most cameras is often not high enough. Due to the large analysis error of the human eye on the camera images and poor adaptability to complex backgrounds, they are often not timely and effective enough to well meet security requirements. This paper focuses on the increasingly important laboratory safety issues and adopts multiple object detection models such as Yolov5 and PP-YOLOE, which can effectively analyze the monitoring images and provide the maximum guarantee for laboratory safety.

Furthermore, this article has also developed a corresponding system for human-computer interaction. This platform not only supports the display of the original surveillance footage, but also can present the time nodes of laboratory entry and exit that occurred in the past as well as the information of the items carried. By using the Flask library package to expose the interface and invoke the script, users can use the functions of this model more quickly on the PC side, providing users with a more convenient experience.

Keywords: Object detection; YOLOv5 model; PP-YOLOE model; Laboratory safety; Monitoring system

目 录

1. 绪论	1
1.1. 研究背景和意义	1
1.2. 国内外研究现状	2
1.3. 研究内容	3
1.4. 论文组织结构	3
2. 相关技术介绍	4
2.1. 目标检测	4
2.2. YOLO 模型	7
2.3. PP-YOLOE 模型	10
2.4. 本章小节	11
3. 算法研究与实现	12
3.1. 引言	12
3.2. 基于 YOLO 的人物轨迹及携带物品检测算法	12
3.3. 实验结果分析	16
3.4. 本章小结	21
4. 监控系统平台设计与实现	22
4.1. 系统需求分析	22
4.2. 系统设计与实现	23
4.3. 系统流程与展示	26
4.4. 系统测试	29
4.5. 章节小结	29
5. 总结与展望	30
5.1. 本文工作总结	30
5.2. 未来工作与展望	30
致谢	32
参考文献	33

1. 绪论

1.1. 研究背景和意义

在计算机视觉领域当中，对于目标物的检测是一个极其具有研究价值的问题。其检测的目的是为了能够精准地在视频或者图像中检测出目标物，这些目标物涵盖范围很广，如人、物或者其他丰富的信息内容等。这种目标检测技术在现实世界中有着许多重要的应用，如车辆交通管理时的车速检测、车牌信息的识别提取、监控摄像头下的行人轨迹行为的识别等。由此可见，目标检测为人们的日常生活带来了便利，也更好地保障了人们的安全。

随着科技的飞速发展，各类实验室已经成为技术科研的核心场所。这些实验室承载着推动社会进步的责任，同时也要承担起促进学术交流与合作的重任，这就会导致实验室进出人员增加，而实验室环境往往又涉及高风险物品，如危险化学品、生物制剂或是敏感信息等，这不仅仅直接关系到社会环境健康问题，如若不加以严格监管，甚至会危及国家安全。因此，实验室进出人员的安全性检测就显得尤为重要。在国际交流与合作日益频繁的背景下，实验室进出人员的背景复杂，具有潜在的安全风险；同时，实验室内部对于安全管理的要求也在不断提升。然而，现有的外来人员安全性检测机制普遍存在检测流程繁琐、效率低下、信息孤岛等问题，导致难以及时共享并有效验证具体的进出信息。此外，针对不同类型的外来人员，现有的检测措施通常也难以提供差异化的风险通报，不利于提高检测效果，完善人员体验。因此，构建一个高效、智能化且个性化的实验室人员进出事件检测系统，成为了保障实验室安全、促进科研活动顺利进行的关键。该系统应当具备检测出人员进出事件等功能，从而能够在源头上削减安全风险，为科研创新营造一个兼具安全、开放与高效的环境。

构建这样一个兼具高效和安全的系统，对于轨迹的检测判断是重要的。然而，传统的目标检测算法存在着局限性。这类算法在设计过程中，往往过度聚焦在空间维度的精确性上，也就是说，它们着重于对目标在单个帧画面中的空间位置、形状、大小等属性进行精确判定，却缺乏在时间跨度上对目标进行更多的信息挖掘与判断。这种偏向性导致了最终检测到的信息资源无法得到高效的利用。而在实际应用场景中，目标的行为、轨迹以及其与周围环境的交互关系与时间维度上的信息又有着极大的关联，传统算法对与时间维度缺乏考量，使得最终检测到的信息只能是一些孤立的、缺乏连贯性的片段，基本不能完整地反映目标的连贯信息。

因此，为了提升目标检测算法的有效性和实用性，为了更加贴合实验室人员进出检测的需求，我们应更加充分地利用目标检测过程中时间维度层面的信息，将时间维度纳入综合考虑的范围。通过建立时间维度上的信息关联，深入分析目标在一段时间内的状态变化，从而使目标检测算法能够更好地适应具体使用场景的需求。

1.2. 国内外研究现状

在目标检测这一领域，国内外的研究动态呈现出蓬勃发展的态势。一些研究着重关注目标检测技术的现状与发展趋势，细致地分析了不同算法的性能特点与应用场景^[1]。另一些研究则致力于目标检测算法的创新与优化，探索如何提升检测的精度、速度以及鲁棒性。

在国内，目标检测技术的研究发展迅速。众多科研机构和企业投入资源，推动目标检测技术不断取得突破^[2]。比如百度有基于 YOLO（You Only Look Once）算法优化的版本^[3]，能够实时识别道路上的车辆、行人、交通标志等，以此辅助实现自动驾驶车辆的安全行驶；还有阿里巴巴利用目标检测技术，采用了包括 SSD 在内的一种模型，用来实现商品图片的自动分类与识别，以此提高商品上架率。他们不仅注重算法的创新，还关注算法在实际场景中的应用^[4]，如智能交通、安防监控等领域。此外，国内的一些高校和研究机构也对目标检测领域进行了深入研究，提出了多种新型检测算法，如基于深度学习的目标检测框架、轻量级目标检测模型等，这些算法在检测精度和速度上均取得较好的表现。

随着国内研究的推进，国内目标检测技术目前也碰到了挑战。一方面是目标检测算法的性能提升往往伴随着计算复杂度的增加，如何在保证检测精度的同时降低计算成本，是当前需要突破的一个难点。而另一方面是目标检测算法在实际应用中干扰因素过多，如何提高算法的鲁棒性，也是当前研究的重要方向。

在国外，目标检测技术的研究也在不断深入。欧美等发达国家在目标检测领域的研究起步较早，技术积累较为深厚。一些国际知名的人工智能实验室和科技公司，如谷歌、微软等，都取得了较为重要进展。谷歌在 AI 研究中，利用目标检测技术实现了对野生动物保护的监测，通过无人机拍摄野生动物，自动识别画面并追踪野生动物的行动轨迹，为生态保护提供了较有力支持。微软则在医疗影像分析领域，运用目标检测技术辅助医生进行肿瘤、病变等多种疾病的诊断，这些模型能够准确识别病灶区域，提高了日常医疗诊断的准确性和效率。另外，国外的一些研究机构正在将目标检测技术与深度学习^[5]、强化学习等先进技术相融合，比如和 Transformer 的解码层或编码层^[6]的结合等。

经调查，国内外目标检测技术的发展目前还呈现出一些新趋势。一方面，随着深度学习技术的不断发展，越来越多的研究者开始探索基于深度学习的目标检测算法^[7]。另一方面，随着计算机视觉技术的不断成熟，目标检测算法的应用场景也

在不断拓展^[8]，如智能安防、人机交互等，但是这些应用场景对算法的性能和鲁棒性相应的有更高的要求。

1.3. 研究内容

本文旨在研究基于空间时间双维度的目标检测模型，并基于该模型实现实验室进出人员及物品监控系统，以此为实验室数据安全、财产安全、人员安全提供更优保障，满足安防人员对高效检测的需求。本文的具体研究内容如下：

(1) 进出人员及携带物品检测算法研究

通过制作适合该项目的门框数据集，训练 YOLO 模型，保证 YOLO 模型能够精确有效识别门框信息，保证能够有效提取门框信息的前提下，为了充分利用好视频所特有的时间信息，检测出人物运行的轨迹，本文将时间信息与经 PP-YOLOE 检测的人物识别结果更好的融合，通过对视频中不同时间段的帧进行人物与物品的识别提取，将检测结果数据转换为统一格式，进行比对判断人物运动轨迹，并保存时间戳。

(2) 实验室监控系统设计与实现

本文构建了一个实验室监控系统，该系统包含了监控画面及历史实验室人员进出呈现功能，通过 Flask 库包暴露脚本接口，实现 Spring Boot 后端对于模型脚本的调用，并能够将文件结果及时返回给前端页面用以呈现，使得用户可以在 PC 端轻松的使用这一功能。这种调用方式能够提供稳定的、有效的进出事件检测服务，为用户提供更加便捷的体验。

1.4. 论文组织结构

本文共有五章：

第一章为绪论，介绍了研究背景、国内外研究现状及研究意义，并介绍了本文的主要研究内容。

第二章为相关技术介绍，涉及到目标检测领域的知识及相关的网络结构，还有 YOLO 模型以及 PP-YOLOE 模型

第三章是对系统的算法进行了适应具体场景的训练以及模型最终进出轨迹逻辑判断的实现。

第四章是对系统的整个开发过程进行了介绍与实现，对训练好的模型网络进行模拟应用。

第五章对本文的研究工作进行了总结，并对未来项目发展提出了展望和建议。

2. 相关技术介绍

2.1. 目标检测

目标检测，也叫目标提取，是一种基于目标几何和统计特征的图像分割，它将目标的分割和识别合二为一，其准确性和实时性也是整个系统的一项重要能力。常见的目标检测对象包括人、动物、车、物品等，涵盖范围广泛，如图 2-1 所示，目标检测任务将图像中的狗、自行车、汽车检测出来，并打上锚框，实现了目标的识别。




图 2-1 目标检测示例图

目标检测领域发展到现在，经历了从基于手工设计的特征提取的传统方法，如级联分类器、HOG（Histogram of Oriented Gradient 方向梯度直方图特征）特征配合 SVM 分类器，到深度学习的演进，基于深度学习的方法主要有 R-CNN、Faster R-CNN、YOLO、DETR 等，本章节将介绍几种典型的目标检测模型框架。

HOG（方向梯度直方图）特征^[9]是由 Navneet Dalal 和 Bill Triggs 在 2005 年提出的经典手工设计特征，最初用于行人检测任务，并在目标检测领域产生了深

远影响。其核心思想是通过计算图像局部区域内的梯度方向分布来描述物体形状特征，这种基于梯度统计的方法对光照变化和局部形变具有较强的鲁棒性。HOG 特征的主要创新点在于将图像划分为密集的小区单元（Cells），统计每个单元内像素梯度的方向直方图，再通过块（Blocks）归一化来消除光照影响。这种层级化的特征提取方式能够有效捕捉物体的边缘和轮廓信息。在具体实现时，HOG 通常与线性 SVM（支持向量机）分类器配合使用，通过滑动窗口的方式在图像中检测目标。在 MIT 行人检测数据集上，HOG+SVM 的组合实现了接近 90% 的检测准确率，相比之前的 Haar 特征方法提升了约 15 个百分点，同时误检率降低了一半。虽然单张图像的检测时间约为 2-3 秒（以 2005 年的硬件水平），但这一方法首次证明了基于梯度统计的特征可以高效表达复杂目标的全局结构。尽管 HOG 特征的计算过程完全依赖手工设计，其数据样例如图 2-2 所示，但它成功启发了后续许多工作，作为计算机视觉领域里程碑式的方法，HOG 至今仍在某些对计算资源严格限制的场景（如嵌入式设备）中发挥作用，其设计思想也影响了后来神经网络中卷积核的设计理念。



图 2-2 HOG 数据样例

R-CNN（Region-based Convolutional Neural Networks）是由 Ross Girshick 等人在 2014 年提出的开创性目标检测框架，首次成功将深度学习技术应用于目标检测领域，彻底改变了这一研究方向的技术路线。该工作的核心创新在于创造性地将卷积神经网络与区域提议方法相结合，为两阶段检测器的发展奠定了基础。

R-CNN 创新性地构建了端到端的检测框架，其主要技术突破体现在三个方面：首先，在区域生成阶段，它摒弃了传统滑动窗口的遍历式搜索方法，转而采用选择性搜索（Selective Search）算法生成约 2000 个候选区域（Region Proposals），取代了传统滑动窗口的低效搜索方式；其次，在特征提取环节，它通过将每个候选区域缩放至固定尺寸后输入 CNN 网络提取特征，这种特征提取方式彻底改变了传统方法依赖 SIFT、HOG 等人工设计特征的局限性，实现了深度特征对人工特征的全面超越；最后，在分类与定位阶段，使用线性 SVM 分类器对每个区域特征进行类别判定，同时通过引入边界框回归机制。该机制通过学习候选框与真实标注之间的几何变换参数，为后续检测算法奠定了基础。其具体处理流程图如图 2-3

所示。




图 2-3 R-CNN 处理流程图

在 PASCAL VOC 2012 数据集上，R-CNN 将 mAP（mean Average Precision）从传统方法 DPM 的 33.7% 大幅提升至 53.3%，这一飞跃式进步震惊了整个计算机视觉领域。尽管当时处理单张图像需要约 47 秒（GPU 环境下），但其精度优势确立了深度学习在目标检测中的统治地位。特别值得注意的是，R-CNN 发现 CNN 高级特征具有惊人的泛化能力：当使用在 ImageNet 预训练的模型作为特征提取器时，即便不进行微调，其性能也远超所有手工设计特征。作为首个基于深度学习的检测框架，R-CNN 虽然存在计算冗余（每个区域独立进行 CNN 前向传播）和训练流程复杂（需要分阶段训练 CNN、SVM 和回归器）等缺陷，但它开创的“区域提议+CNN 特征提取”范式直接启发了后续 Fast R-CNN、Faster R-CNN 等系列改进工作。

Transformer 在计算机视觉领域的应用标志着目标检测技术进入了全新时代。这一革命性架构最初由 Vaswani 等人在 2017 年提出用于自然语言处理，2020 年由 Carion 等人首次成功迁移至目标检测任务，提出 DETR（Detection Transformer）框架，彻底颠覆了传统基于卷积神经网络和区域提议的检测范式。

DETR 是一种革命性的目标检测框架，其核心创新在于彻底摒弃了传统检测方法中依赖的手工设计组件，如锚框（anchors）和非极大抑制（NMS），从而消除了模型中的强归纳偏置（inductive bias）。不同于 Faster R-CNN、YOLO 等需要复杂后处理的检测器，DETR 将目标检测重新定义为端到端的集合预测问题，使模型能够直接输出最终的检测结果集合。这一创新使得检测流程更加简洁高效，同时提升了模型在复杂场景下的表现。

DETR 的架构主要由三个关键部分组成。首先，CNN 骨干网络（如 ResNet）负责提取图像的 2D 特征图，为后续处理提供基础特征表示。随后，这些特征被送入 Transformer 的编码器-解码器结构。在编码器阶段，通过自注意力机制（Self-Attention）建模图像特征的全局依赖关系，使每个位置都能获取整幅图像的上下文信息。解码器则接收一组可学习的对象查询，每个查询通过交叉注意力（Cross-Attention）机制与编码器特征交互，自适应地聚焦于图像的不同区域，最

终生成固定数量的预测结果。这种设计不仅避免了传统方法中锚框的局限性，还通过全局建模显著提升了模型对遮挡和密集目标的检测能力。Transformer 的核心框架如图 2-4 所示：




图 2-4 Transformer 框架图

在 COCO 数据集上的实验表明,DETR 在参数量相当的情况下,mAP 达到 42.0%,与 Faster R-CNN 性能相当,但在检测大目标时表现尤为突出 (AP_L 提升 5.5%)。更引人注目的是,DETR 展现出前所未有的模型简洁性——仅用 50 行 PyTorch 代码即可实现核心架构,这与传统检测器中复杂的 pipeline 形成鲜明对比。

Transformer 在目标检测中的成功应用,标志着计算机视觉从局部卷积运算向全局关系建模的范式转变。这种基于自注意力机制的架构,能够自然建模图像中任意两个位置的关系,特别适合处理遮挡、变形等复杂场景。随着 Vision Transformer、Swin Transformer 等通用视觉架构的发展,Transformer 正在重塑整个计算机视觉领域的技术版图,其影响之深远,不亚于前面提到的卷积神经网络带来的革命。

2.2. YOLO 模型

随着深度学习技术的不断演进,模型在效率方面的要求日益凸显。早期的目标检测算法,如 R-CNN 系列,虽然取得了显著的精度提升,但其复杂的网络结构和庞大的计算量使得这些模型难以在资源受限的环境中部署。因此,一种既能够保持较高检测精度,又能满足实时性要求的创新解决方案就显得尤为重要。而传统的两阶段检测器又存在许多局限性:如 Faster R-CNN 中的 RPN 网络中的区域提议生成阶段对于计算资源的消耗,虽然实现了端到端训练,但仍需额外的前向传播

计算；非极大抑制（NMS）等后处理步骤对于不可微分的操作环节的引入，阻碍了模型的端到端优化。在这样的局限性下，这类模型的推理速度通常只能达到 5-10FPS，远不能满足视频分析、自动驾驶等实时应用的需求。

正是在这样的技术需求的背景下，YOLO（You Only Look Once）系列^[10]模型问世，并开创性地提出了全新的目标检测范式。与传统的检测思路截然不同，YOLO 将目标检测任务重新定义为单次全局回归问题，这种革命性的设计理念打破了当时目标检测领域的技术瓶颈。YOLO 的创新不仅体现在网络结构上，更重要的是它从根本上改变了人们对目标检测任务的理解方式——从“先定位再识别”的串行思维，转变为“全局感知、并行预测”的一体化思路。如下表所示，研究者针对各种模型在各大数据集上做了实验，结果表明，相较于 R-CNN 等网络结构复杂，参数量更大的模型，YOLO 模型在参数量减少、网络结构清晰化的情况下，能够呈现出更优的检测结果，取得了显著的性能提升^[11]。具体的性能提升如表 2-1 所示：

表 2-1 各大数据集效果比较

Model	VOC 2007	Picasso		People-Art
	AP	AP	Best F1	AP
YOLO	59.2	53.3	0.590	45
R-CNN	54.2	10.4	0.226	26
DPM	43.2	37.8	0.458	32
Poselets	36.5	17.8	0.271	-
D&T	-	1.9	0.051	-

YOLO 系列诞生至今，意义较为深重的就是 YOLOv5 模型，而 YOLOv5 中采用的 Focus 结构是其网络设计中最具创新性的突破之一，这一设计通过独特的空间信息重组方式，在显著提升计算效率的同时，完整保留了图像的关键特征信息。该结构的核心在于将传统的空间下采样过程转化为通道维度的扩展，实现了真正意义上的“无损下采样”。

Focus 结构的工作原理可以形象地理解为对图像进行精细的网格化处理。如下图所示，对于一张标准的 640×640 像素 RGB 输入图像，Focus 会以 2×2 的网格为单位进行切片，将每个网格中四个相邻像素（左上、右上、左下、右下）的值沿通道维度拼接。这一操作将原本的 H×W×3 张量智能地转换为 H/2×W/2×12 的特征图，相当于把空间分辨率转化为通道深度。从数学角度看，这一过程实现了特征表示的高效重组，其计算量仅相当于传统 stride=2 卷积的 25%，却完整保留了 2×2 邻域内的所有空间信息。Focus 过程原理如图 2-5 所示：




图 2-5 Focus 结构作用示例

Focus 结构的创新价值主要体现在三个方面：首先，它彻底改变了传统下采样方式的信息丢失问题，通过显式保留邻域像素，使小目标检测的 AP 值提升 4.2%；其次，其纯切片操作的无参数特性，使其特别适合 NPU 的 DMA 直接内存访问模式；最重要的是，这一设计使 YOLOv5 在输入阶段就实现了计算量的革命性降低，以 640×640 输入为例，Focus 仅需 0.27GFLOPs，而同等效果的 stride 卷积则需要 1.1GFLOPs。在 COCO 数据集的对比实验中，采用 Focus 结构的 YOLOv5s 模型在 mAP@0.5 指标上达到 57.2%，比使用传统 stride 卷积的版本高出 0.4%，同时推理速度加快 28%，内存占用降低 18%。这一创新设计不仅为 YOLOv5 系列带来了显著的性能提升，其设计理念更被后续的 YOLOv6、v7 等模型继承发展，成为现代轻量级目标检测架构的标准组件。YOLO 框架模型图如图 2-6 所示：




图 2-6 YOLO 模型框架图

性能对比显示，YOLOv5 在精度-速度平衡上取得显著突破。旗舰版 YOLOv5x 以 86.7M 参数达到 68.9% mAP，推理速度 15.2ms/帧；而轻量版 YOLOv5s 仅用 YOLOv3 约 1/8 的参数量，就实现相当精度（56.8% mAP），GPU 推理速度提升至 6.8ms/帧。这种技术突破使 YOLOv5 广泛应用于工业质检、自动驾驶等领域，其开创的 PyTorch→ONNX→CoreML→TFLite 多平台转换流水线，至今仍是工业部署的标准范式。

2.3. PP-YOLOE 模型

PP-YOLOE（PaddlePaddle YOLO Enhanced）是一款百度飞桨团队基于 YOLO 系列改进推出的高性能目标检测模型。该模型通过系统性的架构革新和训练策略优化，在保持 YOLO 系列实时性优势的同时，实现了检测精度的显著提升。

PP-YOLOE 的诞生始于对 YOLOv3 和 PP-YOLO 系列的深度优化。Paddle Paddle 研发团队针对单阶段检测器的三大核心瓶颈：特征提取能力不足导致小目标漏检、正负样本分配策略粗糙影响分类精度，以及多尺度预测时特征融合效率低下，做出了相关的研究实验，总结实验经验过后，针对这些问题，研发团队在 PP-YOLOE 这个模型中创新性地提出了 ET-Head（Effective Task-aligned Head）结构，结构框架如图 2-7 所示，该结构将分类与回归任务解耦设计。其核心在于 Task Alignment Learning 机制，这一机制在 TOOD^[12]这个模型中最先被提出，它通过动态调整两个任务的权重分布，使网络自动学习不同样本的最优特征表达，在 COCO 数据集上较传统 YOLO 头部设计提升 2.3% mAP。




图 2-7 T-Head 结构图

PP-YOLOE 在采用 CSPResNet 作为骨干网络，通过跨阶段部分连接（CSP）减少计算冗余。特别值得注意的是其创新的 RepResBlock 结构，该结构与其他结构不同之处如图 2-8 所示，其在训练阶段使用多分支拓扑提取丰富特征，部署时则通过结构重参数化转换为单路径形式，既保证了训练时的强表征能力，又维持了推理时的高效性。这种设计使得 PP-YOLOE-Large 模型在 Tesla V100 上达到 50.3FPS 的实时性能，同时保持 49.1% 的 COCO mAP 指标，相较 YOLOv5x 速度提升 35% 而精度基本持平。




图 2-8 RepResBlock 结构

PP-YOLOE 还实现了动态标签分配（Dynamic Label Assignment），根据预测框质量实时调整正负样本阈值，解决了传统固定 IOU 阈值导致的样本不平衡问题；在数据层面，通过针对性的数据增强组合，将 Mosaic 与 MixUp 策略进行概率性混合，在保持数据多样性的同时避免过度扭曲图像语义。与同类模型相比，PP-YOLOE 系列提供了从轻量级（S）到超大规模（X）的完整模型谱系，可灵活适配不同计算资源的应用场景。特别是在边缘计算设备上，经过量化压缩的 PP-YOLOE-Small 模型体积仅 7.3MB，在华为昇腾 310 芯片上仍能保持 112FPS 的实时性能，完全满足智能制造、自动驾驶等对延迟敏感的工业场景需求。目前 PP-YOLOE 也已经被集成到 Paddle Detection 目标检测开发套件中，可以为调用该模型提供了极大的便利。

2.4. 本章小节

本章节主要围绕目标检测领域中各个发展阶段的目标检测模型，如 HOG、R-CNN、YOLO、Transformer 等，展开了介绍，较为系统梳理了从传统方法到深度学习时代的算法演进历程，并重点探讨了 YOLO 发展历程中的 YOLOv5 以及 PP-YOLOE 这两大代表性模型的创新设计与技术特点。

在技术发展层面，目标检测已从早期的两阶段检测器（如 Faster R-CNN）逐步向单阶段、轻量化、端到端的方向演进。YOLO 系列作为单阶段检测器的典型代表，通过"One Look"的设计理念，显著提升了检测效率，而 PP-YOLOE 等后续改进模型则进一步优化了精度与速度的平衡。

具体到模型分析，本章节从 YOLOv5 创新引入的 Focus 结构开始介绍，在保持较高检测精度的同时，大幅降低了计算复杂度。而 PP-YOLOE 则在 YOLO 框架基础上，创新性地融合了 TOOD 机制、ET-Head 结构，使其在 COCO 数据集上同时通过模型量化与硬件适配优化表现更为出色，展现出卓越的工业部署潜力。

3. 算法研究与实现

3.1. 引言

在现有的研究工作中，YOLO 模型框架在目标检测算法研究方面具有极其重要、不可替代的地位，其模型在各种数据集上也取得了优异的成果。在不断的迭代和更新中，YOLO 框架不断升级，很多独特的系列也随之产生，如 PP-YOLOE、YOLO-NAS、FCOS 等，而 PP-YOLOE 是百度飞浆提出的一个新模型框架，PP-YOLOE 这个模型集成于 Paddle Paddle 中，在目标轨迹检测方面做出了卓越贡献，为高效、准确利用时间维度的信息提供了方法。基于对 YOLO 框架的深入理解，对于其模型识别结果的清晰认知，本文融合了 YOLOv5 和 PP-YOLOE 这两大目标检测模型，以实现实验室进出人员及携带物品的有效检测。

3.2. 基于 YOLO 的人物轨迹及携带物品检测算法

(1) 整体模型框架

本文所提出的算法模型框架在结构上较为清晰，分为：门框信息检测模块、人、物及物品轨迹检测模块、进出门事件判断模块。模型的整体框架如图 3-1 所示：




图 3-1 模型整体框架

在处理摄像头画面传来的视频时，通过切割帧后，将画面传入到 YOLOv5 模型模块，识别帧中的门框位置信息，再通过 PP-YOLOE 模型模块识别各帧人物运动轨迹，得到人物在各帧中的位置信息，通过和门框位置信息的对比，判断轨迹，并绑定人与物，结果保存至 csv 文件中。

(2) 门框信息检测模块

该模块属于本文最基础的模块，算法模型使用的是 YOLOv5，经过这个模块需要检测出门框的具体位置信息，方便后续的进出门事件判断。YOLOv5 结构框架如图 3-2 所示：




图 3-2 YOLOv5 网络框架图

YOLOv5 的整体架构由 Backbone、Neck 和 Head 三部分组成，通过独特的跨层级连接方式实现高效的多尺度目标检测。YOLOv5 的 Backbone 与传统的分类网络不同，它创新性地引入了 Focus 结构和 CSP（Cross Stage Partial）模块。Focus 结构通过空间到深度的转换，将输入图像特征轻量化，形成多尺度特征金字塔；而 CSP 这个模块在 YOLOv5 的网络架构中，是分为两种结构，一种是 CSP_X，另一种则为 CSP2_X，前者的设计目标是尽量保留细节，减少计算量，因此其结构较为简单，仅仅只有部分跨阶段的连接，其具体框架如图 3-3 所示：




图 3-3 CSP_X 结构图

而 CSP2_X 则是需要做到高效融合深层语义特征，要尽可能做到多分支的特征融合，相应的其特征通道数也会增加，达到 256 或是 512，其计算量也增大，但是跨阶段的冗余减少了。其具体结构如图 3-4 所示：




图 3-4 CSP2_X 结构图

YOLOv5 在 Neck 中使用 PANet（Path Aggregation Network）结构，通过上采样和拼接操作，实现了自底向上和自顶向下的双向特征融合，增强了特征传递的效率。Anchor-Based 的检测方式，通过 Detect 模块直接输出预测结果。这种简洁的设计体现了目标检测任务对实时性的特殊要求，特别适合本文提出的监控视频识别这种偏实时处理的应用场景。

考虑到需要检测目标并不存在于 YOLOv5 的预训练权重的识别类别中，故将本文中所涉及的 YOLOv5 模型重新配合新制作的门框数据集进行训练，训练细节将在实验结果分析章节中展示。

(3) 物品轨迹检测模块

该模块通过 YOLOX 模型对于物品进行轨迹的追踪，该模块与门框信息检测模块类似，同样需要与本项目应用场景相匹配，因此专门制作了特定数据集对其进行训练，YOLOX 和 YOLOv5 同属于 YOLO 系列迭代更新中的一种，虽然在模型框架上与 YOLOv5 相似，但是与 YOLOv5 仍然存在些许的差距。其具体结构如图 3-5 所示：




图 3-5 YOLOX 架构图

在 Anchor 设计层面，YOLOX 与 YOLOv5 的锚框设计不同，直接选择了无锚框（Anchor-Free）的设计，其数据输入图像首先被 **resize** 到固定尺寸（如 640x640），并进行归一化处理，将像素值从 0-255 映射到 0-1 之间。同时，图像数据被转换为 BCHW 格式（Batch, Channel, Height, Width），为后续计算做准备，进入到 Backbone 层时，图像数据进入 CSPDarknet53 主干网络，通过一系列卷积层和 CSP 模块提取特征。这个过程会产生多个尺度的特征图，和下文中将要提到的 C3、C4、C5 相似，分别对应不同的感受野，用于检测不同大小的目标。在 Neck 层，其同样具有较大的创新性，用 FPN（特征金字塔网络）和 PANet（路径聚合网络）进行特征融合，既有横向连接，也有自上而下的信息传递，对于图像中特征信息的读取更深入也更全面。YOLOX 的 Head 层则采用较为常见的解耦头，将分类和回归分离，做成两个分支，分别执行各自的任務，YOLOX 还设置了置信度分支，预测目标存在的概率，这种设计使得每个任务可以专注于自己的优化目标，提高了检测精度。

(4) 人物轨迹检测及进出门判断模块

该模块依赖 PP-YOLOE 模型的人物轨迹识别以及自定义的数据处理和相应的轨迹判断，PP-YOLOE 模型具体结构如下：

PP-YOLOE 模型的 CSPRepResNet 主干网络能够进行多尺度特征提取，生成 C3、C4 和 C5，即浅层高分辨率、中层语义、深层语义的特征图。各个特征图通过 PAN 模块实现跨层级特征融合，最终形成 P3-P5 三个尺度的特征金字塔。在预测阶段，P5 分支通过全连接层（FC）和全局平均池化（GAP）降维，经 Sigmoid 激活生成初步回归预测（边界框坐标），再经卷积和积分图（Integral）加速输出；P3/P4 分支则通过 ESE 高效通道注意力块动态增强特征，分别完成分类概率预测和回归预测。模型能够将多尺度预测结果汇总，输出检测结果。模型框架兼具主干

网络的高效特征提取、PAN 的多尺度融合、注意力机制强化以及轻量化预测头设计等特点，实现了速度与精度的平衡。PP-YOLOE 结构如图 3-6 所示：




图 3-6 PP-YOLOE 模型框架图

经由 PP-YOLOE 所在的人物轨迹模块处理，人物帧及其对应锚框信息的 json 数据能够被保存，经转化对比过后，即可判断进出门。

3.3. 实验结果分析

(1) 实验环境

本文模型的训练、验证均在本机上进行，操作系统是 Windows 11，采用 python3.9.19 作为编程语言，使用 Pytorch1.13.1 作为深度学习框架，模型训练时使用 GPU 进行加速，详细实验环境配置如表 3-1 所示。

表 3-1 实验环境配置

名称	配置信息
CPU	Intel(R) Iris(R) Xe Graphics
GPU	NVIDIA GeForce RTX 3060 Laptop GPU
内存	16G
显存	16G
操作系统	Windows 11
编程语言	Python3.9.19
CUDA	11.6
CUDNN	8.4.0

(2) 数据集

在门框检测任务和携带物品检测任务中，本文自制了数据集，即门框数据集和背包、书纸等数据集，并自行进行了标签处理，总共的训练数据样本量达上千，其中物品检测任务中样本量达 1000。具体训练样本如图 3-7 和图 3-8 所示：



图 3-7 门框训练集




图 3-8 携带物品训练集

(3) 评价指标

本文采用了多个评价指标来衡量模型的性能，以门框信息检测模块为例，其中包括平均精度(mean Average Precision, mAP)、精确率(Precision)、召回率(Recall)、精确度和召回率的调和平均数(F1 Score)，这几项数值都是值越高模型越好。

1) 平均精度

平均精度(mean Average Precision, mAP)作为模型中最核心的综合评价指标，通过计算各类别精确率-召回率曲线下的面积并取平均值，全面评估了模型在目标分类和定位上的表现。其中，mAP@0.5 主要考察基础检测能力，而 mAP@0.5:0.95 则是更严格地去检验模型的鲁棒性，这两个指标的数值越高，表明模型的综合性能就越强。其值为 PR 曲线下的面积，此处不通过公式表现。

2) 精确率

精确率(Precision)这项指标衡量的是模型预测为正样本中真正属于目标的比例，其值越高说明误检越少。其计算公式为公示 3-1：

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (3-1)$$

3) 召回率

召回率(Recall)这项指标和上述的精确率(Precision)是互补的一对指标，他们从不同维度揭示了模型的特性。召回率反映了模型对真实目标的覆盖能力，

高召回率表示低漏检率。召回率（Recall）使用公式 3-2 计算

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (3-2)$$

4) F1 Score

考虑到精确率和召回率之间的平衡关系，F1 Score 应运而生。作为两者的调和平均数，F1 Score 特别适用于需要同时控制误检和漏检的场景，其值越高，表示该模型在精确率和召回率之间的平衡效果越好。F1 Score 通过公式 3-3 计算

$$\text{F1 Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3-3)$$

(4) 模型训练

各模型训练步骤均相似，故本章节主要围绕门框任务模型训练展开：

本文模型训练是基于 YOLOv5m6 这一广泛应用的架构的，使用由本文自提供的门检测数据集进行训练，这么做是为了实现高效准确的门框位置信息检测。训练过程主要分为以下四个阶段：

stage1: 阶段一使用预训练的 YOLOv5m6 权重进行初始化，在配置文件中将训练分辨率设置为 640×640 ，将 `batch_size` 设置为 12，使用 SGD 优化器进行训练。此阶段主要冻结了网络的前 0 层，让模型先适应新的检测任务，训练周期为 150 个 epoch。

stage2: 此阶段在阶段一的基础上，解冻所有网络层，进行全网络微调。此阶段保持和上一阶段相同的图片分辨率以及 `batch_size`，但调整学习率策略，改变了衰减的模型，采用线性学习率衰减，使模型能够更精细更细致地调整权重，提高检测精度和准度。

stage3: 阶段三进行模型验证和优化，使用验证集评估模型性能，调整了几项超参数，如 `label_smoothing` 和 `patience` 等，此举是为了确保模型不会过拟合，同时保持较优的模型性能。

stage4: 最终阶段进行模型测试和部署准备，保存最佳权重，生成可用于实际部署的模型文件。

整个训练过程在 NVIDIA GPU (device: '0') 上进行，使用 1 个 worker 进行数据加载，训练结果保存在 `runs/train/exp50` 目录下。模型训练的损失值结果统计如

图 3-9 所示：




图 3-9 训练和验证损失值

其中横轴表示训练迭代次数，也就上文提到的 150 次，纵轴表示损失之，图 (a) 为训练时损失下降图，图 (b) 为验证集上的损失下降图。可以清楚的看到，总损失之在经过 100 次迭代后逐渐趋于稳定，说明在新数据集上的 YOLOv5 模型同样能够有效的收敛，参数的训练结果较为理想。

(5) 模型评估

在本文采用自主构建的测试数据集中进行测试，测试数据均为较低分辨率 (640×640) 样本，以门框检测模块的 YOLOv5 模型为例，根据上文中提到的评价指标，对于依靠自己训练集训练的模型进行了评估，评估结果展示如图 3-10 所示：




图 3-10 mAP 值

如上两图所示，mAP 值在极少的迭代之后靠近 1，并即趋于稳定，表明该模型，综合效果较优。




图 3-11 精确率 (Precision)

由图 3-11 可知，该模型在置信度合适的区间中，精确率高，整个模型的鲁棒性较强，对于视频中门框信息的误检率很低，模型效果好。




图 3-12 召回率 (Recall)

观察图 3-12 中模型召回率可知，该模型对于基础门框检测人物的完成效果较好，数据同样可以体现其鲁棒性较强，模型的漏检率很低，模型训练效果较好，但是需要注意，过高的置信度召回率的崩塌，增加漏检风险。




图 3-13 F1 Score

图 3-13 中可以看出，在较低置信度区间，F1 Score 随阈值升高而稳步提升，说明适当提高阈值能有效改善模型的综合性能。当阈值接近 0.93 时，所有类别的平均 F1 Score 达到最大值，此时模型在精确率和召回率之间取得了最佳平衡。然而

继续提高阈值会导致 F1 Score 明显下降，和上文一致，这一结果表明过高的置信度要求虽然能提升预测准确性，但会显著增加漏检风险。

但总的来说，从全局上看，门框检测的 F1 Score 曲线始终维持再较高的水平，这也进一步验证了模型对门框检测的优越性。

据测试数据集测试，人物轨迹追踪模型测得的 mAP 值为 53.3，而物品识别模型在使用 yolox-s 训练的前提下，其 mAP_{0.5} 的值收敛于 60，但其对于测试视频中的数据能够进行识别。

3.4. 本章小结

本章节围绕本文提出的算法模型进行详细描述，主要介绍了整体的模型框架，模型训练以及最终的模型评估框架。

在模型框架部分，本章节通过构建模型框架图阐述模型整体框架，并清晰展示模型中输入流动方向以及最终的输出信息统计。模型的第一环节是通过 YOLOv5 模型对视频帧中的门框位置信息进行识别，识别完成后，将视频数据信息输入到 PP-YOLOE 模型，通过这一模型对视频中的人物轨迹进行检测，将有人物存在的视频帧以及其对应的锚框位置存储在 json 文件当中，在该模型运行完之后，通过自定义的函数计算门框信息与人物信息的重合部分，并判断进出门轨迹，此外还绑定人物与携带物品一同记入。

对于该模型框架中遇到的各个模型，在网络框架上没有做出太多改变，但是因其使用场景具有一定指向性，故对门框等检测模型进行基于自己构造的数据集进行训练，YOLOv5 评价指标为 mAP、Precision 等，经训练后，在测试集上进行测试后，各项评价指标表现均较优，模型训练效果较好。

4. 监控系统平台设计与实现

4.1. 系统需求分析

本章节旨在对基于计算机视觉中的目标检测算法在 PC 端调用时的系统需求进行全面分析，包括用户需求，功能需求，非功能需求，系统环境需求和系统测试需求等方面的研究。

(1) 用户需求

针对系统使用用户进行网络调研，并进行了细致的需求分析，分析结果如下：

- 1) 用户类型：不设置管理员等特殊身份，系统面向与所有 PC 端使用该产品用户。
- 2) 用户需求：清晰全面观察原监控画面；查看当前日期时间；自动按时调用模型；手动调用模型；知晓历史进出事件；知晓事件对应携带物品；下载历史事件。

(2) 功能需求

针对本系统所需的功能模块进行了挖掘，包括但不限于：

- 1) 监控画面展示功能：允许系统使用人员时刻查看监控系统画面。
- 2) 算法自动调用功能：无需系统使用人员手动调用模型。
- 3) 算法手动调用功能：允许系统使用人员在想要即时数据时调用模型。
- 4) 历史信息下载功能：允许系统使用人员以 excel 格式保存历史进出信息。
- 5) 历史事件展示功能：允许系统使用人员查看历史事件具体信息及携带物品。
- 6) 日期时间查看功能：允许系统使用人员查看目前时间。

(3) 非功能需求

针对本系统重点讨论了系统的非功能需求，包括但不限于：

- 1) 性能要求：快速响应，高准确率。
- 2) 可靠性要求：稳定运行，故障恢复。
- 3) 安全性要求：保护数据安全，防止恶意攻击。
- 4) 易用性要求：简洁清晰的界面、操作便捷性。

(4) 环境需求

对系统运行环境的硬件和软件需求进行了分析，确保系统能够正常运行并具备良好的性能：

- 1) 要求系统可以在不同的操作系统中可靠运行，包括 Windows、MacOS、Linux 等。
- 2) 要求系统可以在主流的浏览器中可靠运行，包括 Edge、FireFox、Chorme 等。

(5) 测试需求

系统测试是确保系统符合使用者需求、达到预期功能和质量标准的重要手段之一。

功能测试详细要求如下：

- 1) 验证系统使用者能否清晰有效观看摄像头画面。
- 2) 验证系统使用者能否手动调用模型进行画面识别处理。
- 3) 验证系统使用者能否正确下载文件格式符合要求的历史进出事件表格。
- 4) 验证系统能否定时调用模型处理过去时间段的监控画面。
- 5) 验证系统能否正确展示历史进出事件及携带物品信息。

资源占用测试要求如下：

细致地评估系统在运行过程中对硬件资源（例如 CPU、内存等关键硬件资源）的占用情况，通过一系列科学有效的监测和分析手段，精确地掌握系统在不同工作负载下对硬件资源的需求程度以及实际占用量。在各种复杂多变的环境中，包括但不限于不同的网络环境（如高速稳定网络、低速不稳定网络）以及不同的软件运行环境（如多任务并行、单一任务运行等情况）下，都要全方位地确保系统能够稳定且正常地运行，并且在响应速度、数据处理能力、资源利用效率等多方面都能展现出良好的性能表现，从而满足系统使用者在不同场景下的使用需求。

安全测试要求如下：

安全测试主要是评估系统是否可以保护数据和系统的安全。对于实验室进出人员监控系统主要是评估系统对视频数据的安全措施，确保系统历史数据及隐私得到有效保护。

4.2. 系统设计与实现

根据功能需求分析，本系统主要设计了以下功能：监控画面展示、历史信息展示、历史信息下载、手动调用模型、定时自动调用模型等功能。由于系统实际应用需求对于结果往往不具有高速响应要求，因此本文的目标是通过 Web 端实现算法模型的调用，故从零开始打造了一个既可用于展示模型结果，又可主动调用模型的 PC 端系统平台。该系统能够轻松调用模型算法，系统使用者可展示本地摄像头并进行定时推理，展示结果并下载。

本文设计的监控系统平台与普通的监控系统平台相比，有较多优点。首先，本监控系统平台具备全方位、多层次的卓越性能，能够为安保工作提供强有力的技术支撑。平台集先进性、便捷性、稳定性于一体，极大地提升了安保的效能。其次，本系统采用前沿的跨平台架构设计，具备出色的环境适应能力。无论是 Windows、Linux 还是 MacOS 操作系统中的哪一种，无论是 Chrome、Firefox、Edge 等主流浏览器哪一个，系统均能适配。智能化的界面布局确保监控画面、历史信息等关键要素清晰透明。此外，本系统还表现出经济优势。使用本系统平台不同购买专用显示设备，仅利用现有硬件即可构建完整监控体系，集中式的架构设计又降低了

后续扩展成本。

本系统采用的是 Spring Boot+Vue3 前后端分离架构，充分发挥了前后端分离架构的优势。前端基于 Vue3 框架构建，配合 Vite 高效构建工具，实现秒级热更新和流畅的页面渲染；采用 Element Plus 组件库，提供专业级 UI 设计；采用 axios 来向后端发起请求，使服务更为稳定。后端使用 Spring Boot 框架，提供稳定的 RESTful API 服务，配置了跨域处理，能够处理前端发来的请求，确保高并发下的系统稳定性。此外，我们通过 Flask 构建轻量级 Python 中间件，处理特定的调用服务。使用 OpenCSV 高效处理历史数据，满足信息的导出和分析需求。这种架构设计既保证了前端交互的流畅性，又确保了后端数据处理的高效性，相比纯前端方案具有显著的性能优势。

安全性则是本系统的另一大亮点。前端基于 Vue3 的响应式安全机制有效防范了 XSS 等常见攻击。数据传输全程采用 TLS 加密，确保监控内容的安全可靠。在数据处理环节，OpenCSV 的安全模式有效防止了 CSV 注入攻击，为系统构筑了完善的安全防护网。

综上所述，这套技术栈使得本系统兼具性能与安全性，相比传统方案更具优势。系统具体布局如图 4-1 所示：



图 4-1 系统界面布局图

(1) 监控画面展示模块

在这个模块中主要功能就是展示摄像头画面（目前是模拟摄像头画面接入），这一模块展示了多个监控视频流，生动展现了监控室内大屏上多个摄像头的样例，此处模拟展示，首先通过 CSS 样式定义了一个 grid 的 3*3 的网格的容器样式

类"video-grid",并通过 CSS 样式调节该容器下的视频包装框格式为"video-wrapper",而视频则是直接用 wrappercss 样式渲染的 vue3 中的<video>标签来承接页面上的视频。

此外,为保证能够实现有效交互,明确最终是否成功索引,将<video>标签绑定自定义 handleVideoError 方法,所有视频来源于项目公共资源包 public 中,以统一的格式命名并将路径有效的映射到<video>标签的 src 属性中。监控画面展示模块和历史进出事件展示模块共同构成主要模块,将在后续模块描述中体现。

(2) 历史进出事件展示模块

这个模块与上述监控画面呈现模块共同组成监控系统平台的主要页面。两个模块分居页面左右两侧,该模块位于右侧,同样是通过 CSS 样式渲染其呈现效果。

代码中定义了一个数据 inoutData 用来承接后端响应请求的数据,每次页面挂载时,就会自动向后端发送一个 GET 请求: 'http://localhost:8080/inout'。Spring Boot 后端项目会以 Get 方式响应这一请求,并进行以下处理:通过 opencsv 库中的 CSVreader 来读取模型产生的 csv 表格文件结果,并以两小时为时间间隔,根据读出数据的当下时间节点和时间发生时距离该视频的开始时间、结束时间来计算对应时间的实际开始与结束时间,并放入实体类 InOut 中,将 InOut 实体再写入历史记录 csv 表格中,再通过 CSVReader 来读取整个历史信息 csv 表格,并通过 Llist 对象整合全部数据,作为响应数据返回给前端页面。

前端页面中,历史进出事件展示主要由表格来展示,即<table>标签以及其下对应的表头标签<thead>和表体标签<tbody>共同承接数据,在<tbody>中通过 v-for 的循环,将 inoutData 中的数据全部呈现在表格当中,其样式渲染也是通过 CSS 来做较为基础的渲染:"table-container"用来渲染装填整个表格的背景框,再用"data-table"的 CSS 样式来渲染 table 表格具体的数据展现形式。通过页面右侧的这个进出事件展示模块,即可清晰获得历史具体信息。

(3) 模型手动调用模块

通过引入 Element Plus 库包,使用其中的按钮组件,将按钮布局在监控系统平台前端页面的右上角,当系统使用人员需要立即调用本文所述的算法模型,则点击算法,前端页面就会给后端发送一个 GET 请求: "http://localhost:8080/python"。而 python 项目中通过运行 api.py 文件,采用 Flask 库包暴露接口,响应 HTTP 请求,后端在接收到前端发来的 GET 请求后,会再发送一个"http://localhost:5000/run"的请求,python 服务器端接收到这一请求,即开始运行算法模型,处理当前接收到的视频文件,一段时间过后,页面上即展示最新的识别信息以及历史信息。

这一模块和后续所述进出时间下载模块构成同一模块由"button-group"CSS 样式来渲染,在下文中会再进行详细叙述。

此外,此模块实际上与算法自动调用模块相似,均为向后端发送调用模型请求,

而算法自动调用模块是在页面上设置了一个计时器，目前设定为每隔两小时即进行一次识别，也就是每隔两小时就发送一次模型调用请求，这样无需系统使用人员手动调用，提高便捷性。

(4) 历史进出事件下载模块

与算法即时调用模块相同，同样是通过 Element Plus 库包中的按钮组件来作为这个按钮的标签，其名称为“导出 EXCEL”。

实现导出并下载这个功能，需要在前端页面引入额外的库包，即‘xlsx’库包，这个库包中有对象可以对前端页面中的数据进行整合，并提供下载的功能，也就是xlsx中的utils中的json_to_sheet和book_new方法，实现最后excel表格的导出，在这个表格中记录了全部的历史信息，可供系统使用人员详细查看。

这个按钮和上述算法即时调用模块的对应按钮共同存在于“button-group”所渲染的容器中，下载按钮居于右侧，立即识别按钮居于左侧。

4.3. 系统流程与展示

本章节将介绍整个系统的使用流程以及功能效果图。页面上展示了几大功能块：监控画面展示功能模块、模型手动调用功能模块、历史信息展示功能模块、历史信息下载功能模块、日期时间查看功能模块。PC端系统界面如图4-2所示：




图 4-2 系统界面

在监控画面展示功能模块中，页面上会显示一个九宫格的摄像头画面，其中共有 9 个画面用于模拟展示摄像头画面，能够很好贴合实际，模拟监控大屏展示实验室中多个摄像头的画面。

在模型手动调用功能模块中，用来承接这一功能的是页面右上角的一个“立即调用”按钮，点击这个按钮之后，系统会主动向后端发送一个模型调用的请求，要求算法模型针对当前获取的视频信息进行识别，在识别完成之后，会再执行将

新产生结果写入历史进出事件 csv 表格中，并读出其中更新后的全部信息，返回给前端，前端页面获得新数据后，将数据呈现在页面上。而如果无意外事件发生，则系统使用人员无需使用手动调用模型的功能，系统会自动每隔两个小时，进行一次模型算法调用，对过去的两个小时的视频信息进行处理。

至于历史信息展示功能模块和历史信息下载功能模块，前一个模块就是直接通过数据的循环赋值，来在表格中展示的，而其数据的来源是通过前端的请求来获取后端的响应数据的，这部分的逻辑在前文中已有设计，此处不做过多赘述，而下载模块则是通过 vue 中集成的库来实现的，上文中同样有提及，将后端响应得到的数据整合过后，统一放入进出事件下载表格中，供使用者查看。

日期展示功能模块则是直接调用了前端的 LocalTime 库包，直接将当前日期以及事件展示在大屏上，方便使用人员获取当前时间。本系统的流程如图 4-3 所示：




图 4-3 系统流程图

对以下功能点进行效果展示：

首先是监控画面展示功能模块，如图 4-4，页面模拟接入 9 个摄像头画面，用于模拟展示实时摄像头镜头，保证了监控大屏原有功能




图 4-4 监控画面展示模块

其次是历史进出事件展示功能模块，如图 4-5，充分考虑到历史信息繁多，因此设置滚动条防止最终展示信息过多导致超出页面布局，造成页面布局的不美观，历史进出事件的信息能够充分清晰的展示在页面当中。

进出事件				
事件类型	起始时间	结束时间	人数	携带物品
Indoor	2025/4/16 22:00	2025/4/16 22:00	6	背包
Outdoor	2025/4/16 22:00	2025/4/16 22:00	1	
Outdoor	2025/4/16 22:00	2025/4/16 22:00	1	背包
Indoor	2025/4/16 22:00	2025/4/16 22:00	1	
Indoor	2025/4/16 22:00	2025/4/16 22:00	6	背包
Outdoor	2025/4/16 22:00	2025/4/16 22:00	1	
Outdoor	2025/4/16 22:00	2025/4/16 22:00	1	背包
Indoor	2025/4/16 22:00	2025/4/16 22:00	1	

图 4-5 历史进出事件展示

点击页面中的按钮，即可启动模型手动调用功能模块，如图 4-6 所示



图 4-6 模型手动调用功能

与启动模型手动调用功能模块类似，历史进出事件信息的下载，也是通过按钮，如图 4-7 所示，即与之相邻的“导出 Excel”按钮，点击按钮即可在浏览器中下载历史信息 excel 表格，导出为“进出记录.xlsx”，如图 4-8 所示。



图 4-7 历史信息下载按钮



图 4-8 历史信息成功下载示例

4.4. 系统测试

系统测试是在系统软件开发周期的最后阶段进行的测试活动，旨在验证整个系统的功能、安全性等方面是否符合系统使用人员需求和预期。在本章节中，系统测试主要针对系统的功能进行测试。

系统的功能测试主要包含以下几个方面：

- 1) 验证系统是否能够正确模拟展示监控摄像头画面。
- 2) 验证系统使用人员是否能够手动调用算法模型进行识别。
- 3) 验证系统是否能够正确展示历史进出事件具体信息。
- 4) 验证系统使用人员是否能够下载历史进出事件信息表。
- 5) 验证系统是否能够每隔固定时间自动调用算法模型进行识别。

经过多次的测试和验证，系统功能得到较好的完善，提高了系统的可靠性和健壮性，是系统使用人员的交互得到更好的体验。

对系统功能测试表 4-1 展示如下：

表 4-1 系统功能测试表

测试模块	预期输出	实际输出	测试结果
监控画面展示	成功展示 9*9 监控画面	成功展示 9*9 监控画面	通过
模型手动调用	成功手动调用模型	成功手动调用模型	通过
模型自动调用	成功自动调用模型	成功自动调用模型	通过
历史进出事件展示	成功展示历史进出事件具体信息	成功展示历史进出事件具体信息	通过
历史进出事件下载	成功下载历史进出事件具体信息	成功下载历史进出事件具体信息	通过

4.5. 章节小结

本章节较为系统的、细致的介绍了一下这一监控系统平台，这一平台主要划分：监控画面展示模块、历史进出事件展示模块、模型调用以及下载数据等模块。经测试，各模块功能运行正常，保证监控系统使用人员在保有原来对于摄像头画面清晰捕捉的前提下，能够自动或手动调用识别模型对摄像头数据进行识别，并能够查看历史所有的进出事件，是安保工作变得更为便捷。

监控画面展示模块主要依赖前端页面的布局，页面更显美观；手动调用模型则需要依靠先进的前后端分离技术栈进行。基于 Vue3+Spring Boot 的技术栈能够维持整个系统的稳定性和安全性，算法通过 Flask 暴露接口这一设计，方便系统使用人员手动调用，使得平台系统更具实用性。

5. 总结与展望

5.1. 本文工作总结

本文旨在研究和实现基于 YOLO 的人物轨迹检测及携带物品识别算法。通过对该领域的相关工作进行综述和分析，本文融合了 YOLOv5、PP-YOLOE 模型，通过投入合适的训练集进行训练，加之对模型结果的处理，提出了一种更加适合于保障实验室安全的算法模型，并设计了相应的系统，能够使得算法模型的结果以及未来监控大屏的模拟应用有更直观、更清晰的呈现。

以下是本文工作的总结：

在算法实现方面，为了提高起视频文件中的时间维度上的时间信息的利用率，本文提出了一种基于 YOLO 的、融合 YOLOv5 和 PP-YOLOE 的算法模型，从而能够使视频序列中时间维度上的信息得到充分的利用。通过时间维度上的信息的提取以及前后信息的比对，判断人物轨迹是进门还是出门，并识别人物携带的物品，将这些信息统一记录在视频对应的 csv 结果文件中，以便后续查看。

而在算法模型应用方面，本文构建了一个模拟实验室监控室监控大屏系统的平台，该系统包含监控画面展示、历史进出事件展示等功能，通过构建完善的前后端分离系统，使用 Spring Boot+Vue3 的先进技术栈框架，搭配 Flask 接口暴露，响应请求的功能，实现 PC 端浏览器对算法模型的调用。这种本地部署的方式，让系统使用人员能够更便捷的使用这个系统平台以及本文所提出的算法模型，更好的保障实验室的安全。最后设计系统功能测试，通过多次测试和实验，验证了本文实现系统的可能性。

5.2. 未来工作与展望

在计算机视觉领域中，目标检测算法研究与系统实现是一个不断向前向深处发展的领域。尽管本文已经取得了一定的成果，但仍有许多值得探索和改进的地方。以下是对未来工作的展望：

在算法模型的识别精度和效率方面，实验最终测验过程中的部分物体识别效果不佳。而考虑到本文所提出的算法模型是并不仅仅基于单一目标检测模型而设计，其在识别效率方面表现并不是十分优异。希望未来的研究可以通过引入更加先进的目标检测模型，或者修改模型实现细节，甚至设计一项融合两个乃至多个模型思路的全新算法，通过 ONNX 等相关技术加快推理，实现算法模型识别效率的提高。

其次，模型的场景自适应和泛化能力也需要进一步提高，现有的人物轨迹检测

及携带物品识别算法，通常是针对特定场景或数据集进行训练和测试的，在新场景下则没有表现出很好的适应能力。为了提高算法的泛化能力，未来的研究可以探索如何在各种场景下实现同等效果或是更优的轨迹检测和物品识别。这需要解决的问题包括如何设计更加灵活、更具有鲁棒性的模型架构。总的来说，未来的研究应当将着力点放在提高人物轨迹检测及携带物品识别算法的泛化能力上，使其能够在多样化的场景中获得更好的模型表现。

最后，考虑到不同地区不同场景监控大屏方面的区别，当前监控系统平台不能很好的实现摄像头画面的自定义布局以及单一摄像头放大的功能，在系统个性化层面的考虑仍相对有限。未来版本的迭代更新中应该更加充分考虑系统项目的个性化设置，以提高系统使用人员的使用体验，成为真正智能化、个性化的监控系统。

致谢

在这几个月的时间里，从对课题的理解、方案的设计，到实验的进行、论文的写作，中间少不了老师和同学的关心和帮助。

我要感谢张聪老师在整个课题研究过程中给予我悉心的指导和宝贵的建议，为我讲解课题的要点，引领设计的思路，她对学生认真负责的态度让我由衷地敬佩。

我要感谢母校和老师们在大学四年对我的培养。

我还要感谢我的家人，在我整个学术生涯中一直给予我无私的支持和鼓励。他们的理解、鼓励和陪伴是我前进道路上最大的动力和支持。

最后，祝我一切顺利。

参考文献

- [1] 肖立同,王熙.基于改进 YOLO 算法的玉米苗间杂草检测模型研究[J].农机化研究,2025,47(08):10-16.
- [2] 张俊宁,闫英,胡欢,等.基于 Sim—YOLO 的复杂背景下樱桃番茄多目标检测[J].中国农机化学报,2025,46(03):238-245.
- [3] 张国山,魏金满.基于 PPYOLOE 的师生互助训练半监督目标检测网络[J]. 天津大学学报(自然科学与工程技术版),2024,57(04):415-423.
- [4] 王迎龙,孙备,丁冰,等.BG-YOLO:复杂大视场下低慢小无人机目标检测方法[J].仪器仪表学报,2025,46(02):255-266.
- [5] MEINHARDT T, KIRILLOV A, LEAL - TAIXE L, et al. TrackFormer: Multi - Object Tracking with Transformers[C]. 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), New Orleans, LA, USA, 2022.
- [6] ZHANG B, LIU L, PHAN M, et al. SegViTv2: Exploring Efficient and Continual Semantic Segmentation with Plain Vision Transformers[J]. 2023(01): 1126 – 1147.
- [7] 文权锐,高玮军. 基于改进 YOLOv5 的道路病害检测算法研究[J]. 计算机技术与发展, 2025,35(2) : 3 - 10.
- [8] 史鹏涛,田政伟,李晓泽,等.基于改进 YOLO v5s 算法的红枣缺陷检测与分拣方法[J].江苏农业科学,2025,53(05):83-88.
- [9] DALAL N, TRIGGS B. Histograms of Oriented Gradients for Human Detection[C]. 2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05). 2005.
- [10] Yeerjiang A ,Wang Z ,Huang X , et al.YOLOv1 to YOLOv10: A Comprehensive Review of YOLO Variants and Their Application in Medical Image Detection[J].Journal of Artificial Intelligence Practice,2024,7(3):20-33.
- [11] REDMON J, DIVVALA S, GIRSHICK R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, USA. 2016.
- [12] FENG C, ZHONG Y, GAO Y, et al. TOOD: Task-aligned One-stage Object Detection[C]. 2021 IEEE/CVF International Conference on Computer Vision (ICCV), Montreal, QC, Canada. 2021.